# Linear Models



Ciencia y analítica de datos (Gpo 10)

Alumno: Armando Bringas Corpus (A01200230)

Profesores: Dra. María de la Paz Rico Fernández, Mtra. Victoria Guerrero Orozco

Fecha: 9 de noviembre de 2022

- In supervised learning, the training data fed to the algorithm includes the desired solutions, called labels.
- In **regression**, the labels are continuous quantities.
- Linear models predict by computing a weighted sum of input features plus a bias term.


```
from jupyterthemes import jtplot
jtplot.style(theme='monokai', context ='notebook', ticks =True, grid =False)
import numpy as np
%matplotlib inline
import matplotlib
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
from sklearn import metrics
from sklearn.linear_model import LinearRegression
from sklearn.linear_model import Lasso
from sklearn.linear model import Ridge
from sklearn.metrics import r2_score
from sklearn.model selection import train test split
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import PolynomialFeatures
from sklearn.preprocessing import StandardScaler
# to make this notebook's output stable across runs
np.random.seed(42)
```

#### Simple Linear Regression

[0.15599452],

- [0.05808361],
- [0.86617615],
- [0.60111501],
- [0.70807258],
- [0.02058449],
- [0.96990985],
- [0.83244264],
- [0.21233911],
- [0.21200011]
- [0.18182497],
- [0.18340451],
- [0.30424224],
- [0.52475643],
- [0.43194502],
- [0.29122914],
- [0.61185289],
- [0.13949386],
- [0.29214465],
- [0.36636184],
- [0.45606998],
- [0.78517596],
- [0.19967378],
- [0.51423444],
- [0.59241457],
- [0.04645041],
- [0.60754485],
- [0.17052412],
- [0.06505159],
- [0.94888554],
- [0.96563203],
- [0.80839735],
- [0.30461377],
- [0.09767211],
- [0.68423303],
- [0.44015249],
- [0.12203823],
- [0.49517691],
- [0.03438852],
- [0.9093204],
- [0.25877998],
- [0.66252228],
- [0.31171108],
- [0.52006802],
- [0.54671028], [0.18485446],
- [0.96958463],
- [0.77513282],
- [0.93949894],
- [0.89482735],
- [0.59789998],
- [0.92187424],
- [0.0884925],
- [0.19598286],
- [0.04522729],
- [0.32533033],

```
[0.38867729],
       [0.27134903],
       [0.82873751],
       [0.35675333],
       [0.28093451],
       [0.54269608],
       [0.14092422],
       [0.80219698],
       [0.07455064],
       [0.98688694],
       [0.77224477],
       [0.19871568],
       [0.00552212],
       [0.81546143],
       [0.70685734],
       [0.72900717],
       [0.77127035],
       [0.07404465],
       [0.35846573],
       [0.11586906],
       [0.86310343],
       [0.62329813],
       [0.33089802],
       [0.06355835],
       [0.31098232],
       [0.32518332],
       [0.72960618],
       [0.63755747],
       [0.88721274],
       [0.47221493],
       [0.11959425],
       [0.71324479],
       [0.76078505],
       [0.5612772],
       [0.77096718],
       [0.4937956],
       [0.52273283],
       [0.42754102],
       [0.02541913],
       [0.10789143]])
X = 2*np.random.rand(100, 1)
y = 4 + 3 * X + np.random.randn(100, 1)
plt.scatter(X, y);
```



```
3.508550
0
     8.050716
1
2
     6.179208
3
     6.337073
4
    11.311173
          . . .
. .
95
     5.441928
96
    10.121188
97
     9.787643
98
     8.061635
99
     9.597115
[100 rows x 1 columns]
linear_reg = LinearRegression(fit_intercept=True)
linear_reg.fit(X, y)
```


#### LinearRegression()

Plot the model's predictions:

```
\#X\_fit[]
```

```
# construct best fit line
X_fit = np.linspace(0, 2, 100)
y_fit = linear_reg.predict(X_fit[:, np.newaxis])

plt.scatter(X, y)
plt.plot(X_fit, y_fit, "r-", linewidth=2, label="Predictions")
plt.xlabel("$X$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.legend(loc="upper left", fontsize=14);
```



Predictions are a good fit.

Generate new data to make predictions with the model:

```
X_new = np.array([[0], [2]])
```

```
X_new
array([[0],
       [2]])
X_new.shape
(2, 1)
y_new = linear_reg.predict(X_new)
y_new
array([[ 3.74406122],
       [10.47517611]])
linear_reg.coef_, linear_reg.intercept_
(array([[3.36555744]]), array([3.74406122]))
The model estimates:
\hat{y} = 3.36X + 3.74
#/VENTAS/GANANCIAS/
#COEF*VENTAS+B
# | VENTAS | COMPRAS | GANANCIAS |
#C0EF1*X1+C0EF2*X2+B=Y
```

# **Polynomial Regression**


If data is more complex than a straight line, you can use a linear model ti fit non-linear data adding powers of each feature as new features and then train a linear model on the extended set of features.

to 
$$y = a_0 + a_1 x_1 + a_2 x_2 + a_3 x_3 + \dots$$
 
$$y = a_0 + a_1 x + a_2 x^2 + a_3 x^3 + \dots$$

This is still a linear model, the linearity refers to the fact that the coefficients never multiply or divide each other.

To generate polynomial data we use the function:

```
y = 0.50X^2 + X + 2 + noise
\# \ generate \ non-linear \ data \ e.g. \ quadratic \ equation
m = 100
X = 6 * np.random.rand(m, 1) - 3
y = 0.5 * X**2 + X + 2 + np.random.randn(m, 1)
plt.plot(X, y, "b.")
plt.xlabel("$x_1$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.axis([-3, 3, 0, 10]);
```



# pd.DataFrame(y)

8.529240 0 1 3.768929 2 3.354423 3 2.747935 0.808458 4 95 5.346771 96 6.338229 97 3.488785 98 1.372002 99 -0.072150

# [100 rows x 1 columns]

Now we can use PolynomialFeatues to transform training data adding the square of each feature as new features.


```
poly_features = PolynomialFeatures(degree=2, include_bias=False)
X_poly = poly_features.fit_transform(X)
X_poly
array([[ 2.72919168e+00, 7.44848725e+00],
                          2.03741795e+00],
       [ 1.42738150e+00,
                          1.06357069e-01],
       [ 3.26124315e-01,
       [ 6.70324477e-01,
                          4.49334905e-01],
       [-4.82399625e-01,
                          2.32709399e-01],
       [-1.51361406e+00,
                          2.29102753e+00],
       [-8.64163928e-01,
                          7.46779295e-01],
                          2.39344620e+00],
       [ 1.54707666e+00,
       [-2.91363907e+00,
                          8.48929262e+00],
       [-2.30356416e+00,
                          5.30640783e+00],
       [-2.72398415e+00,
                          7.42008964e+00],
       [-2.75562719e+00,
                          7.59348119e+00],
                          4.54868016e+00],
       [ 2.13276350e+00,
       [ 1.22194716e+00, 1.49315485e+00],
       [-1.54957025e-01,
                          2.40116797e-02],
       [-2.41299504e+00,
                          5.82254504e+00],
       [-5.03047493e-02,
                          2.53056780e-03],
       [-1.59169375e-01,
                          2.53348900e-02],
                          3.84469264e+00],
       [-1.96078878e+00,
                          1.57521755e-01].
       Γ-3.96890105e-01.
       [-6.08971594e-01,
                          3.70846402e-01],
       [ 6.95100588e-01,
                          4.83164828e-01],
                          6.57010602e-01],
       [ 8.10561905e-01,
       [-2.72817594e+00,
                          7.44294397e+00],
       [-7.52324312e-01, 5.65991871e-01],
       [ 7.55159494e-01,
                          5.70265862e-01],
       [ 1.88175515e-02,
                          3.54100244e-04],
       [ 2.13893905e+00,
                          4.57506025e+00],
       [ 9.52161790e-01,
                          9.06612074e-01],
       [-2.02239344e+00,
                          4.09007522e+00],
       [-2.57658752e+00,
                          6.63880323e+00],
       [ 8.54515669e-01,
                          7.30197029e-01],
       [-2.84093214e+00,
                          8.07089541e+00],
       [ 5.14653488e-01,
                          2.64868212e-01],
       [ 2.64138145e+00,
                          6.97689596e+00],
                          2.05068655e-01],
       [ 4.52845067e-01,
       [-6.70980443e-01,
                          4.50214755e-01],
                          7.39134488e-01],
       [ 8.59729311e-01,
       [-2.50482657e-01,
                          6.27415615e-02],
                          7.49120928e-02],
       [ 2.73700736e-01,
       [ 2.64878885e+00,
                          7.01608239e+00],
       [-6.83384173e-01,
                          4.67013928e-01],
       [ 2.76714338e+00,
                          7.65708250e+00],
       [ 2.43210385e+00,
                          5.91512915e+00],
       [-1.82525319e+00,
                          3.33154921e+00],
       [-2.58383219e+00,
                          6.67618881e+00],
       [-2.39533199e+00,
                          5.73761535e+00],
       [-2.89066905e+00,
                          8.35596753e+00],
       [-2.43334224e+00,
                          5.92115443e+00],
       [ 1.09804064e+00,
                          1.20569325e+00],
```

```
[-2.57286811e+00,
                   6.61965031e+00],
[-1.08614622e+00,
                   1.17971361e+00],
[ 2.06925187e+00,
                   4.28180328e+00],
                   8.18170730e+00],
[-2.86036839e+00,
[ 1.88681090e+00,
                   3.56005536e+00],
[-1.30887135e+00,
                   1.71314421e+00],
[-2.29101103e+00,
                   5.24873156e+00],
[ 1.18042299e+00,
                   1.39339844e+00],
[7.73657081e-01,
                   5.98545278e-01],
[ 2.26483208e+00,
                   5.12946436e+00],
[ 1.41042626e+00,
                   1.98930224e+00],
[ 1.82088558e+00,
                   3.31562430e+00],
[-1.30779256e+00,
                   1.71032139e+00],
[-1.93536274e+00,
                   3.74562893e+00],
[ 1.50368851e+00,
                   2.26107913e+00],
[ 1.84100844e+00,
                   3.38931206e+00],
                   8.66143060e+00],
[ 2.94303085e+00,
[-5.24293939e-01,
                   2.74884134e-01],
                   5.89657333e-01],
[-7.67891485e-01,
[ 1.65847776e+00,
                   2.75054850e+00],
[-9.55178758e-01,
                   9.12366461e-01],
                   6.67986745e+00],
[ 2.58454395e+00,
[ 2.15047651e+00,
                   4.62454922e+00],
[-4.26035836e-01.
                   1.81506533e-01],
[ 1.50522641e+00,
                   2.26570654e+00],
[ 1.52725724e+00,
                   2.33251469e+00],
                   5.67038389e+00],
[-2.38125679e+00,
[ 2.41531744e+00,
                   5.83375834e+00],
[ 3.15142347e-02,
                   9.93146988e-04],
[ 1.95874480e+00,
                   3.83668118e+00],
[-1.07970239e+00,
                   1.16575726e+00],
[ 2.37313937e+00,
                   5.63179047e+00],
[-6.64789928e-01,
                   4.41945648e-01],
[-2.93497409e+00,
                   8.61407292e+00],
[ 2.43229186e+00,
                   5.91604369e+00],
[-2.45227994e+00,
                   6.01367690e+00],
[-1.08411817e+00,
                   1.17531222e+00],
                   7.29200787e+00],
[ 2.70037180e+00,
[ 2.70364288e+00,
                   7.30968483e+00],
[ 4.40627329e-01,
                   1.94152443e-01],
[ 7.91023273e-01,
                   6.25717818e-01],
                   9.56831113e-02],
[-3.09326868e-01,
[-1.24073537e+00,
                   1.53942426e+00],
                   1.05681017e+00],
[-1.02801273e+00,
[ 1.03511074e+00,
                   1.07145424e+00],
                   2.29294451e+00],
[ 1.51424718e+00,
[ 1.74947426e+00,
                   3.06066019e+00],
[ 1.73770886e+00,
                   3.01963207e+00],
                   6.01604821e+00],
[-2.45276338e+00,
[-3.34781718e-02,
                   1.12078799e-03]])
```

X\_poly now contains the original feature of X plus the square of the feature:

```
print(X[0])
print(X[0]*X[0])
```

```
[2.72919168]
[7.44848725]
X_poly[0]
array([2.72919168, 7.44848725])
Fit the model to this extended training data:
lin_reg = LinearRegression(fit_intercept=True)
lin_reg.fit(X_poly, y)
lin_reg.coef_, lin_reg.intercept_
(array([[1.04271531, 0.50866711]]), array([2.01873554]))
The model estimates:
\hat{y} = 0.89X + 0.48X^2 + 2.09
Plot the data and the predictions:
X_{new=np.linspace(-3, 3, 100).reshape(100, 1)}
X_new_poly = poly_features.transform(X_new)
y_new = lin_reg.predict(X_new_poly)
plt.plot(X, y, "b.")
plt.plot(X_new, y_new, "r-", linewidth=2, label="Predictions")
plt.xlabel("$x_1$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.legend(loc="upper left", fontsize=14)
plt.axis([-3, 3, 0, 10]);
```



# R square

 $R^2$  es una medida estadística de qué tan cerca están los datos de la línea de regresión ajustada. También se conoce como el coeficiente de determinación o el coeficiente de determinación múltiple para la regresión múltiple. Para decirlo en un lenguaje más simple,  $R^2$  es una medida de ajuste para los modelos de regresión lineal.

 $R^2$  no indica si un modelo de regresión se ajusta adecuadamente a sus datos. Un buen modelo puede tener un valor  $R^2$  bajo. Por otro lado, un modelo sesgado puede tener un valor alto de  $R^2$ .

SSres + SSreg = SStot,  $R^2 = Explained variation / Total Variation$ 

# Sum Squared Regression Error $R^2 = 1 - \frac{SS_{Regression}}{SS_{Total}}$ Sum Squared Total Error

$$R^2 \equiv 1 - rac{SS_{
m res}}{SS_{
m tot}}. igozplus 1 - rac{\sum (\mathbf{y_i} - \hat{\mathbf{y_i}})^2}{\sum (\mathbf{y_i} - \hat{\mathbf{y}})^2}$$
 $R^2 = rac{SS_{
m reg}}{SS_{
m tot}}$ 

# Ejercicio 1

Utiliza la base de datos de https://www.kaggle.com/vinicius150987/manufacturing-cost


Suponga que trabaja como consultor de una empresa de nueva creación que busca desarrollar un modelo para estimar el costo de los bienes vendidos a medida que varían el volumen de producción (número de unidades producidas). La startup recopiló datos y le pidió que desarrollara un modelo para predecir su costo frente a la cantidad de unidades vendidas.

df = pd.read\_csv('https://raw.githubusercontent.com/marypazrf/bdd/main/EconomiesOfScale.csv')
df.sample(10)

	Number	of Units	Manufacturing Cost
968		7.065653	27.804027
212		3.372115	41.127212
416		4.194513	43.832711
677		5.068888	41.225741
550		4.604122	37.569764
764		5.389522	31.191501
386		4.104190	42.988730
339		3.942214	46.291435
82		2.665856	48.578425
487		4.399514	37.567914

X = df[['Number of Units']]

```
y = df['Manufacturing Cost']
len(X)
1000
y.describe
<bound method NDFrame.describe of 0 95.066056</pre>
      96.531750
2
       73.661311
3
       95.566843
       98.777013
4
995
      23.855067
996
      27.536542
997
       25.973787
998
       25.138311
999
       21.547777
Name: Manufacturing Cost, Length: 1000, dtype: float64>
plt.plot(X,y,'b.')
[<matplotlib.lines.Line2D at 0x29328388730>]
```



# Datos de entrenamiento y prueba, Funciones Predeterminadas

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, random_state = 42)
# Función para cálculo de errores MAE, RMSE y R-Squered
def calculo_errores(y, y_predict):
    """
    Funcion para calular los errores MAE, RMSE y R-squared
    y -> "y original"
    y -> "y predictora"
    """
    error_MAE = metrics.mean_absolute_error(y, y_predict)
    error_RMSE = np.sqrt(metrics.mean_squared_error(y, y_predict))
    error_r2 = r2_score(y, y_predict)

    print('Error medio Absoluto (MAE):', error_MAE)
    print('Root Mean Squared Error:', error_RMSE)
    print('r2_score', error_r2)

    return error_MAE, error_RMSE, error_r2
```


```
La siguiente función la tomamos del curso de IBM con algunas ligeramos modificaciones
```

```
def PollyPlot(xtrain, xtest, y_train, y_test, lr, poly_transform, title='Regression'):
   training data
   testing data
   lr: linear regression object
   poly_transform: polynomial transformation object
   width = 12
   height = 10
   plt.figure(figsize=(width, height))
   xmax=max([xtrain.values.max(), xtest.values.max()])
   xmin=min([xtrain.values.min(), xtest.values.min()])
   x=np.arange(xmin, xmax, 0.1)
   plt.plot(xtrain, y_train, 'ro', label='Training Data')
   plt.plot(xtest, y_test, 'go', label='Test Data')
   plt.plot(x, lr.predict(poly_transform.fit_transform(x.reshape(-1, 1))), linewidth=3, label='Predict
   plt.title(title, fontsize=20)
   plt.ylabel('Y')
   plt.xlabel('X')
   plt.legend()
Regresión Lineal
Modelo
lin_reg_model = LinearRegression(fit_intercept=True)
lin_reg_model.fit(X_train, y_train)
y_predict = lin_reg_model.predict(X)
Resultados (intersección y coeficientes)
print("*****10)
print(f"intersección: {lin_reg_model.intercept_}")
print(f"coefficientes: {lin_reg_model.coef_}")
print("*****10)
*************
intersección: 67.6960501274973
coefficientes: [-6.17788033]
**************
Errores (MAE, RMSE, R^2)
print("*****10)
lin_reg_MAE, lin_reg_RMSE, lin_reg_r2 = calculo_errores(y, y_predict)
print("*****10)
***************
Error medio Absoluto (MAE): 4.939597008496299
Root Mean Squared Error: 6.874192552027152
r2_score 0.5786435857137199
***************
```

#### Visualización

```
y_hat = lin_reg_model.predict(X_test)

plt.plot(X_train, y_train, 'ro', label='Training Data')
plt.plot(X_test, y_test, 'go', label='Test Data')
plt.plot(X_test, y_hat, label='Predicted Function')
plt.title('Linear Regression', fontsize=20)
plt.ylabel('Y')
plt.xlabel('X')
plt.legend()
plt.show()
```




# Regresión Polinomial

#### Modelo

```
poly_features = PolynomialFeatures(degree=3, include_bias=False)
X_poly = poly_features.fit_transform(X.values)
```

```
X_train_poly = poly_features.fit_transform(X_train.values)
X_test_poly = poly_features.fit_transform(X_test.values)
poly_reg_model = LinearRegression(fit_intercept=True)
poly_reg_model.fit(X_train_poly, y_train)
y_predict = poly_reg_model.predict(X_poly)
Resultados (intersección y coeficientes)
print("*****10)
print(f"intersección: {poly_reg_model.intercept_}")
print(f"coefficientes: {poly_reg_model.coef_}")
print("*****10)
**************
intersección: 113.7238978878948
coefficientes: [-33.90139997  4.87063075  -0.24671164]
*************
Errores (MAE, RMSE, R^2)
poly_reg_MAE, poly_reg_RMSE, poly_reg_r2 = calculo_errores(y, y_predict)
Error medio Absoluto (MAE): 4.491695145471314
Root Mean Squared Error: 5.931601464733989
r2_score 0.6862742608497481
Visualización
PollyPlot(X_train, X_test, y_train, y_test, poly_reg_model, poly_features, 'Polynomial Regression')
```



# Regresión con Ridge

### Modelo

```
poly_features = PolynomialFeatures(degree=3, include_bias=False)
X_poly = poly_features.fit_transform(X.values)
X_train_pr = poly_features.fit_transform(X_train)
X_test_pr = poly_features.fit_transform(X_test)


alpha = 0.005

ridge_model = Pipeline([
    ("poly_features", poly_features),
    ("scaler", StandardScaler()),
    ("ridge", Ridge(alpha=alpha, solver='cholesky', random_state=42))
])

ridge_model.fit(X_train_pr, y_train)
y_pred = ridge_model.predict(X_poly)
```

```
Resultados (intersección y coeficientes)
```

```
print("*****10)
print(f"intersección: {ridge_model.named_steps['ridge'].intercept_}")
print(f"coefficientes: {ridge_model.named_steps['ridge'].coef_}")
print("*****10)
*************
intersección: 40.07822650011423
\texttt{coefficientes:} \ [ -77.95629407 \quad 79.36389222 \ -28.68381857 \quad 79.36389222 \ -28.68381856 \\
-22.26404709 -22.26404708 18.78952616 16.42708908 -28.68381856
-22.26404709 18.78952616 18.78952616 16.42708908 -16.13368489
 16.42708908 -16.13368489 -27.8886696 17.70271199]
*************
Errores (MAE, RMSE, R^2)
print("*****10)
ridge_reg_MAE, ridge_reg_RMSE, ridge_reg_r2 = calculo_errores(y, y_pred)
print("*****10)
**************
Error medio Absoluto (MAE): 4.439115075861926
Root Mean Squared Error: 5.862760553595349
r2_score 0.6935140728267526
*************
Visualización
reg_model_obj = Ridge(alpha=alpha)
reg_model_obj.fit(X_train_pr, y_train)
PollyPlot(X_train, X_test, y_train, y_test, reg_model_obj, poly_features, 'Ridge Regression')
```



# Regresión con Lasso

# Modelo

```
poly_features = PolynomialFeatures(degree=3, include_bias=False)
X_poly = poly_features.fit_transform(X.values)
X_train_pr = poly_features.fit_transform(X_train)
X_test_pr = poly_features.fit_transform(X_test)


alpha = 0.5

lasso_model = Pipeline([
    ("poly_features", poly_features),
    ("scaler", StandardScaler()),
    ("lasso", Lasso(alpha=alpha, random_state=42))
])

lasso_model.fit(X_train_pr, y_train)
y_pred = lasso_model.predict(X_poly)
```

#### Resultados (intersección y coeficientes)

```
print("*****10)
print(f"intersección: {lasso_model.named_steps['lasso'].intercept_}")
print(f"coefficientes: {lasso_model.named_steps['lasso'].coef_}")
print("*****10)
*************
intersección: 40.07822650011428
coefficientes: [-8.73899198 0.
                                     0.
                                                0.
                                                           0.
                                                                      0.
 0.
            1.38761874 0.
                                   0.
                                             0.
                                                         0.09599955
 0.
            0.
                       0.
                                  0.
                                             0.
                                                        0.
          ]
 0.
***************
Errores (MAE, RMSE, R^2)
lasso_reg_MAE, lasso_reg_RMSE, lasso_reg_r2 = calculo_errores(y, y_pred)
Error medio Absoluto (MAE): 4.71793606853768
Root Mean Squared Error: 6.6297462541716685
r2_score 0.6080776442471629
Visualización
lasso model obj = Lasso(alpha=alpha, random state=42)
lasso_model_obj.fit(X_train_pr, y_train)
PollyPlot(X_train, X_test, y_train, y_test, lasso_model_obj, poly_features, 'Lasso Regression')
```



# Comparación de MAE, RMSE y $R^2$ de los cuatro métodos

```
error_comparison = {
    'Method' : ['Linear', 'Polinomial', 'Ridge', 'Lasso'],
    'MAE' : [lin_reg_MAE, poly_reg_MAE, ridge_reg_MAE, lasso_reg_MAE],
    'RMSE' : [lin_reg_RMSE, poly_reg_RMSE, ridge_reg_RMSE, lasso_reg_RMSE],
    'R-squared' : [lin_reg_r2, poly_reg_r2, ridge_reg_r2, lasso_reg_r2],
}

error_comparison = {
    'Error' : ['MAE', 'RMSE', 'R-squared'],
    'Linear' : [lin_reg_MAE, lin_reg_RMSE, lin_reg_r2],
    'Polinomial' : [poly_reg_MAE, poly_reg_RMSE, poly_reg_r2],
    'Ridge' : [ridge_reg_MAE, ridge_reg_RMSE, ridge_reg_r2],
    'Lasso' : [lasso_reg_MAE, lasso_reg_RMSE, lasso_reg_r2]
}


error_comparison_df = pd.DataFrame(error_comparison)
error_comparison_df
```

```
Error
                 Linear
                         Polinomial
                                         Ridge
                                                    Lasso
0
         MAE
              4.939597
                           4.491695
                                      4.439115
                                                4.717936
        RMSE
              6.874193
                                      5.862761
1
                           5.931601
                                                6.629746
              0.578644
                           0.686274
                                      0.693514
2
   R-squared
                                                0.608078
```

'Catplot' para visualizar los errores de los métodos

```
# Aplicamos un 'melt' que es un 'unpivot' de los datos para que podamos graficarlos
error_comparison_melt_df = pd.melt(
    error_comparison_df,
    id_vars="Error",
    var_name="Regression",
    value_name="Error value")
```

sns.catplot(data=error\_comparison\_melt\_df, x="Error value", y="Regression", hue='Error', kind="bar")
plt.show()



#### Explicación de los resultados

Sugerimos ir por el de Ridge ya que es el que cuenta con el menor error ya que se aprecia que podría tener un mejor ajuste, es muy similar su ajuste con respecto al de Regresión Polinomial, ambos tienen un margen de error muy cercano por lo que podemos apreciar en la gráfica de 'catplot'. Sin embargo, para poder determinar de forma más contundente el modelo, recomendamos que se haga un evaluación de puntaje de validación cruzada (cross validation).

Los porcentajes de entrenamiento son de 70% y de prueba de 30% que son con los que generalmente se

comienzan, sin embargo, recomendamos hacer un análisis de 'underfitting' y 'overfitting' para analizar si los resultados no están subajustados o sobreajustados y de esta manera hacer una redefinición de los porcentajes en caso de ser necesario.

Los valores de error son aceptables para este modelo, tenemos un MAE and RMSE dentro de la escala de valores que esperamos, por otro lado, el valor de  $R^2 > 0$ , que nos indica que no hubo algún problema con el ajuste, en ridge y polinomial  $R^2 \approx 0.7$ , el modelo ideal, que ajustará perfectamente tendría una  $R^2 = 1$  lo cual nos habla de que nuestro error es aceptable.

# Ejercicio 2 - Realiza la regresión polinomial de los siguientes datos:

df = pd.read\_csv('https://raw.githubusercontent.com/marypazrf/bdd/main/kc\_house\_data.csv')
df.sample(10)

	id	date	nri	.ce be	drooms	ba <sup>.</sup>	throoms	\	
5954	7852020250	20140602T000000	-		4		2.50	•	
8610	6392002020	20150324T000000			3		1.75		
7650	626049058	20150504T000000			5		2.50		
5683	2202500255	20150305T000000			3		2.00		
20772	1972200428	20140625T000000			3		2.50		
6959	723000114	20140505T000000			5		3.50		
10784	4104900340	20150204T000000			4		2.50		
21528	3416600750	20150217T000000			3		2.50		
12319	2386000070	20141029T000000			4		3.25		
19947	1776460110	20141223T000000	395000	0.0	4		2.75		
	saft living	sqft_lot floo	ra matar	front	view		arada	\	
5954	sqft_living 3190		rs water	0	view 2	• • •	grade 9	\	
8610	1700		.0	0	0		8		
7650	2570		.0	0	0		7		
5683	1210		.0	0	0		7		
20772	1400		5.5	0	0		8		
6959	4010		2.0	0	1		9		
10784	3220		1.0	0	1		10		
21528	1750		3.0	0	0		8		
12319	4360		.0	0	0		10		
19947	2280		2.0	0	0		8		
10011	2200	0010 2		· ·	Ů		Ü		
	sqft_above	-	yr_built	yr_re	novate			lat	\
5954	3190	0	2001		(	0	98065	47.5317	
8610	1700	0	1967		(	0	98115	47.6837	
7650	1300	1270	1959			0	98133	47.7753	
5683	1210	0	1954		201		98006	47.5731	
20772	1400	0	2007			0	98103	47.6534	
6959	2850	1160	1971			0	98105	47.6578	
10784	3220	0	1991			0	98056	47.5326	
21528	1750	0	2008			0	98122	47.6021	
12319	3360	1000	1993			0	98053	47.6398	
19947	2280	0	2009		(	0	98019	47.7333	
	long sq	ft_living15 sqf	t_lot15						
5954	-121.866	2630	6739						
8610	-122.284	1880	6000						
7650	-122.355	1760	7969						

5683	-122.135	1690	9737
20772	-122.355	1350	1312
6959	-122.286	2610	6128
10784	-122.181	2650	11896
21528	-122.294	1940	4800
12319	-121.985	3540	90940
19947	-121.976	2130	5121

[10 rows x 21 columns]

df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21613 entries, 0 to 21612
Data columns (total 21 columns):

#	Column	Non-Null Count	Dtype			
0	id	21613 non-null	int64			
1	date	21613 non-null	object			
2	price	21613 non-null	float64			
3	bedrooms	21613 non-null	int64			
4	bathrooms	21613 non-null	float64			
5	sqft_living	21613 non-null	int64			
6	sqft_lot	21613 non-null	int64			
7	floors	21613 non-null	float64			
8	waterfront	21613 non-null	int64			
9	view	21613 non-null	int64			
10	condition	21613 non-null	int64			
11	grade	21613 non-null	int64			
12	sqft_above	21613 non-null	int64			
13	sqft_basement	21613 non-null	int64			
14	<pre>yr_built</pre>	21613 non-null	int64			
15	<pre>yr_renovated</pre>	21613 non-null	int64			
16	zipcode	21613 non-null	int64			
17	lat	21613 non-null	float64			
18	long	21613 non-null	float64			
19	sqft_living15	21613 non-null	int64			
20	sqft_lot15	21613 non-null	int64			
dtypes: float64(5),		int64(15), object(1)				
memory usage: 3.5+ MB						

# df.describe()

	id	price	bedrooms	bathrooms	sqft_living	\
count	2.161300e+04	2.161300e+04	21613.000000	21613.000000	21613.000000	
mean	4.580302e+09	5.400881e+05	3.370842	2.114757	2079.899736	
std	2.876566e+09	3.671272e+05	0.930062	0.770163	918.440897	
min	1.000102e+06	7.500000e+04	0.000000	0.000000	290.000000	
25%	2.123049e+09	3.219500e+05	3.000000	1.750000	1427.000000	
50%	3.904930e+09	4.500000e+05	3.000000	2.250000	1910.000000	
75%	7.308900e+09	6.450000e+05	4.000000	2.500000	2550.000000	
max	9.900000e+09	7.700000e+06	33.000000	8.000000	13540.000000	
	$sqft_lot$	floors	waterfront	view	condition	\
count	2.161300e+04	21613.000000	21613.000000	21613.000000	21613.000000	
mean	1.510697e+04	1.494309	0.007542	0.234303	3.409430	

```
std
       4.142051e+04
                          0.539989
                                         0.086517
                                                        0.766318
                                                                       0.650743
                                                        0.000000
min
       5.200000e+02
                          1.000000
                                         0.000000
                                                                       1.000000
                          1.000000
25%
       5.040000e+03
                                         0.000000
                                                        0.000000
                                                                       3.000000
50%
       7.618000e+03
                          1.500000
                                                        0.000000
                                                                       3.000000
                                         0.000000
75%
       1.068800e+04
                          2.000000
                                         0.000000
                                                        0.000000
                                                                       4.000000
       1.651359e+06
                          3.500000
                                                        4.000000
                                                                      5.000000
                                         1.000000
max
              grade
                        sqft_above
                                     sqft_basement
                                                         yr_built
                                                                   yr_renovated
       21613.000000
                      21613.000000
                                      21613.000000
                                                    21613.000000
                                                                   21613.000000
count
mean
           7.656873
                       1788.390691
                                        291.509045
                                                      1971.005136
                                                                      84.402258
std
           1.175459
                        828.090978
                                        442.575043
                                                        29.373411
                                                                     401.679240
                        290.000000
                                                      1900.000000
min
           1.000000
                                          0.000000
                                                                       0.000000
25%
           7.000000
                       1190.000000
                                          0.00000
                                                      1951.000000
                                                                       0.000000
50%
           7.000000
                       1560.000000
                                          0.000000
                                                      1975.000000
                                                                       0.000000
                                        560.000000
75%
           8.000000
                       2210.000000
                                                      1997.000000
                                                                        0.00000
          13.000000
                       9410.000000
                                       4820.000000
                                                      2015.000000
                                                                    2015.000000
max
                                                   sqft_living15
                                                                      sqft_lot15
            zipcode
                               lat
                                             long
       21613.000000
                      21613.000000
                                     21613.000000
                                                    21613.000000
                                                                    21613.000000
count
mean
       98077.939805
                         47.560053
                                      -122.213896
                                                      1986.552492
                                                                    12768.455652
std
          53.505026
                          0.138564
                                         0.140828
                                                      685.391304
                                                                    27304.179631
       98001.000000
                         47.155900
                                      -122.519000
                                                      399.000000
                                                                      651.000000
min
25%
       98033.000000
                                      -122.328000
                         47.471000
                                                      1490.000000
                                                                     5100.000000
50%
       98065.000000
                         47.571800
                                      -122.230000
                                                      1840.000000
                                                                     7620.000000
75%
       98118.000000
                         47.678000
                                      -122.125000
                                                      2360.000000
                                                                    10083.000000
max
       98199.000000
                         47.777600
                                      -121.315000
                                                      6210.000000
                                                                   871200.000000
df.drop('id', axis = 1, inplace = True)
df.drop('date', axis = 1, inplace = True)
df.drop('zipcode', axis = 1, inplace = True)
df.drop('lat', axis = 1, inplace = True)
df.drop('long', axis = 1, inplace = True)
plt.figure(figsize=(12,8))
sns.heatmap(df.corr(), annot=True, cmap='Dark2_r', linewidths = 2)
plt.show()
```



Tuvimos que reducir el número de atributos a utilizar para lograr la convergencia de los modelos, si utilizábamos todos los atributos teníamos un error de desbordamiento de memoria, los atributos para estos modelos fueron seleccionados con base al 'heatmap', aquellos que tuvieran una mayor correlación con la 'Y' en este caso: 'sqft\_living', 'grade', 'sqft\_above', 'sqft\_living15'

```
#columns = df.columns.drop('price')
#features = columns
features = ['sqft_living', 'grade', 'sqft_above', 'sqft_living15']
label = ['price']

X = df[features]
y = df[label]

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, random_state = 42)

print(f'Numero total de registros en la bdd: {len(X)}')
print("*****"*10)
print(f'Numero total de registros en el training set: {len(X_train)}')
print(f'Tamaño de X_train: {X_train.shape}')
print("*****"*10)
print(f'Mumero total de registros en el test dataset: {len(X_test)}')
print(f'Tamaño del X_test: {X_test.shape}')
Numero total de registros en la bdd: 21613
```

```
***************
Numero total de registros en el training set: 15129
Tamaño de X train: (15129, 4)
*************
Mumero total de registros en el test dataset: 6484
Tamaño del X test: (6484, 4)
Regresión Lineal
Modelo
lin_reg_model = LinearRegression(fit_intercept=True)
lin_reg_model.fit(X_train, y_train)
y_predict = lin_reg_model.predict(X)
Resultados (intersección y coeficientes)
print("*****10)
print(f"intersección: {lin_reg_model.intercept_}")
print(f"coefficientes: {lin_reg_model.coef_}")
print("*****10)
**************
intersección: [-630229.67952031]
coefficientes: [[ 2.29742473e+02 1.03623835e+05 -8.00558306e+01 2.09001856e+01]]
*****************
Errores (MAE, RMSE, R-squared)
print("*****10)
lin_reg_MAE, lin_reg_RMSE, lin_reg_r2 = calculo_errores(y, y_predict)
print("*****10)
******************
Error medio Absoluto (MAE): 162006.60695814595
Root Mean Squared Error: 248483.81686359108
r2_score 0.5418758377891657
**************
Regresión Polinomial
Modelo
poly_features = PolynomialFeatures(degree=3, include_bias=False)
X_poly = poly_features.fit_transform(X.values)
X_train_poly = poly_features.fit_transform(X_train.values)
X_test_poly = poly_features.fit_transform(X_test.values)
poly_reg_model = LinearRegression(fit_intercept=True)
poly_reg_model.fit(X_train_poly, y_train)
y_predict = poly_reg_model.predict(X_poly)
Resultados (intersección y coeficientes)
print("*****10)
print(f"intersección: {poly reg model.intercept }")
```


```
print(f"coefficientes: {poly_reg_model.coef_}")
print("*****10)
***************
intersección: [450357.13043263]
coefficientes: [[ 6.63515932e+02 -1.05797891e+05 -1.13977634e+02 -6.07233060e+02
  2.07758915e-02 -2.35793475e+02 3.39855881e-01 -9.16167201e-02
  2.18683522e+04 1.61364707e+01 1.53631735e+02 -2.05790316e-01
 -7.84630532e-03 1.01676301e-01 7.13371080e-05 -3.31922465e-02
 -2.40537325e-04 1.22182010e-05 2.20320152e+01 -3.61454518e-03
  4.12960473e-02 3.12707787e-04 2.08715801e-05 -7.07347081e-05
 -1.38489750e+03 3.05198356e+00 -1.37511474e+01 -7.87933132e-04
 -2.32567625e-02 -5.05143502e-03 -1.39369270e-04 2.96969026e-05
 -2.05377633e-05 3.32147430e-05]]
******************
Errores (MAE, RMSE, R^2)
print("*****10)
poly_reg_MAE, poly_reg_RMSE, poly_reg_r2 = calculo_errores(y, y_predict)
print("*****10)
***************
Error medio Absoluto (MAE): 147040.24271547626
Root Mean Squared Error: 232498.00190120665
r2_score 0.5989251510287183
***************
Ridge
Modelo
poly_features = PolynomialFeatures(degree=3, include_bias=False)
X_poly = poly_features.fit_transform(X.values)
X_train_pr = poly_features.fit_transform(X_train)
X_test_pr = poly_features.fit_transform(X_test)
alpha = 0.1
ridge_model = Pipeline([
   ("poly_features", poly_features),
   ("scaler", StandardScaler()),
   ("ridge", Ridge(alpha=alpha, solver='cholesky', random_state=42))
])
ridge_model.fit(X_train_pr, y_train)
y_pred = ridge_model.predict(X_poly)
Resultados (intersección y coeficientes)
print("*****10)
print(f"intersección: {ridge_model.named_steps['ridge'].intercept_}")
print(f"coefficientes: {ridge_model.named_steps['ridge'].coef_}")
print("*****10)
*****************
```

```
intersección: [537640.17317732]
coefficientes: [[ 73755.19455307 257277.29234858 -261344.81272394 ... 115578.17067423
  262797.77381452 140103.45512217]]
***************
Error
print("*****10)
ridge_reg_MAE, ridge_reg_RMSE, ridge_reg_r2 = calculo_errores(y, y_pred)
print("*****10)
**************
Error medio Absoluto (MAE): 150725.9130162672
Root Mean Squared Error: 912340.9941843494
r2_score -5.175915677094912
***************
Lasso
Modelo
poly_features = PolynomialFeatures(degree=3, include_bias=False)
X_poly = poly_features.fit_transform(X.values)
X train pr = poly features.fit transform(X train)
X_test_pr = poly_features.fit_transform(X_test)
alpha = 15
lasso_model = Pipeline([
   ("poly_features", poly_features),
   ("scaler", StandardScaler()),
   ("lasso", Lasso(alpha=alpha, tol=1e-2, random_state=42))
])
lasso_model.fit(X_train_pr, y_train)
y_pred = lasso_model.predict(X_poly)
C:\Users\bring\anaconda3\envs\tec\lib\site-packages\sklearn\linear_model\_coordinate_descent.py:648: Co.
 model = cd_fast.enet_coordinate_descent(
Intersección y Resultados
print("*****10)
print(f"intersección: {lasso_model.named_steps['lasso'].intercept_}")
print(f"coefficientes: {lasso model.named steps['lasso'].coef }")
print("*****10)
**************
intersección: [537640.17317733]
coefficientes: [ 8885.166244
                             39531.83726265 -1835.8176543 ...
                                                              2975.52735624
 30135.7002611 -31414.91345422]
**************
```

```
Error
```

print("\*\*\*\*\*10)


```
lasso_reg_MAE, lasso_reg_RMSE, lasso_reg_r2 = calculo_errores(y, y_pred)
print("*****10)
**************
Error medio Absoluto (MAE): 147842.20914431222
Root Mean Squared Error: 412469.7475706219
r2_score -0.2623249920317994
**************
Visualización de los Errores en los cuatro métodos
error comparison = {
   'Method' : ['Linear', 'Polinomial', 'Ridge', 'Lasso'],
    'MAE' : [lin_reg_MAE, poly_reg_MAE, ridge_reg_MAE, lasso_reg_MAE],
    'RMSE': [lin_reg_RMSE, poly_reg_RMSE, ridge_reg_RMSE, lasso_reg_RMSE],
    'R-squared' : [lin_reg_r2, poly_reg_r2, ridge_reg_r2, lasso_reg_r2],
}
error_comparison = {
   'Error' : ['MAE', 'RMSE', 'R-squared'],
    'Linear' : [lin_reg_MAE, lin_reg_RMSE, lin_reg_r2],
    'Polinomial' : [poly_reg_MAE, poly_reg_RMSE, poly_reg_r2],
    'Ridge' : [ridge_reg_MAE, ridge_reg_RMSE, ridge_reg_r2],
    'Lasso' : [lasso_reg_MAE, lasso_reg_RMSE, lasso_reg_r2]
}
error_comparison_df = pd.DataFrame(error_comparison)
error_comparison_df
      Error
                   Linear
                              Polinomial
                                                 Ridge
0
        MAE 162006.606958 147040.242715 150725.913016 147842.209144
       RMSE 248483.816864 232498.001901 912340.994184 412469.747571
1
2 R-squared
                  0.541876
                                0.598925
                                              -5.175916
                                                            -0.262325
error_comparison_df1 = error_comparison_df.drop([2], axis=0, inplace=False)
error_comparison_df1.reset_index()
   index Error
                      Linear
                                Polinomial
                                                   Ridge
                                                                  Lasso
0
         MAE 162006.606958 147040.242715 150725.913016 147842.209144
      0
      1 RMSE 248483.816864 232498.001901 912340.994184 412469.747571
# Aplicamos un 'melt' que es un 'unpivot' de los datos para que podamos graficarlos
error_comparison_melt_df1 = pd.melt(
   error_comparison_df1,
   id_vars="Error",
   var_name="Regression",
   value_name="Error value")
sns.catplot(data=error comparison melt df1, x="Error value", y="Regression", hue='Error', kind="bar")
plt.show()
```



sns.catplot(data=error\_comparison\_melt\_df2, x="Error value", y="Regression", hue='Error', kind="bar")

error\_comparison\_df2,
id\_vars="Error",
var\_name="Regression",
value name="Error value")

plt.show()



Como podemos observar con esta gráfica tenemos valores de  $R^2 < 0$  para Ridge y Lasso, lo cual nos habla que el modelo no ajusto de forma adecuada con los datos, por lo tanto, no es un modelo válido. Particularmente lo podemos ver en Ridge donde no se logró la convergencia del modelo. Procederemos a realizar la repetición del ejercicio decrementando la cantidad de datos de entrenamiento y prueba y ajustando los parámetros en los modelos.


# Repetición del ejercio modificando los porcentajes de datos de entrenamiento y prueba

```
Tamaño del X_test: (3242, 4)
Regresión Lineal
lin reg model = LinearRegression(fit intercept=True)
lin_reg_model.fit(X_train, y_train)
y_predict = lin_reg_model.predict(X)
print("*****10)
print(f"intersección: {lin_reg_model.intercept_}")
print(f"coefficientes: {lin_reg_model.coef_}")
print("*****10)
print("*****10)
lin_reg_MAE, lin_reg_RMSE, lin_reg_r2 = calculo_errores(y, y_predict)
print("*****10)
***************
intersección: [-611529.11035663]
coefficientes: [[ 2.44683234e+02 9.55019597e+04 -7.35119836e+01 2.24798417e+01]]
*************
**************
Error medio Absoluto (MAE): 164778.3916447209
Root Mean Squared Error: 248835.91020031332
r2 score 0.540576624447485
**************
Regresión Polinomial
poly_features = PolynomialFeatures(degree=3, include_bias=False)
X_poly = poly_features.fit_transform(X.values)
X_train_poly = poly_features.fit_transform(X_train.values)
X_test_poly = poly_features.fit_transform(X_test.values)
poly_reg_model = LinearRegression(fit_intercept=True)
poly_reg_model.fit(X_train_poly, y_train)
y_predict = poly_reg_model.predict(X_poly)
print("*****10)
print(f"intersección: {poly_reg_model.intercept_}")
print(f"coefficientes: {poly_reg_model.coef_}")
print("*****10)
print("*****10)
poly_reg_MAE, poly_reg_RMSE, poly_reg_r2 = calculo_errores(y, y_predict)
print("*****10)
**************
intersección: [37142.04583259]
coefficientes: [[ 2.61705665e+02 3.61181368e+04 1.96803641e+02 -2.82036490e+02
 -4.96479855e-01 -4.98609560e+01 1.14197766e+00 1.06783995e-01
  3.70084373e+03 -1.31751974e+02 5.57209582e+01 -5.93571854e-01
  2.99266750e-02 1.09563380e-02 -3.04975525e-05 7.98937925e-02
 -4.77947308e-05 4.15740537e-05 -4.02570284e+00 -1.35659391e-01
 -2.36318382e-03 2.08607737e-04 -1.45461931e-04 -2.03529442e-06
  5.63832878e+01 2.07235622e+01 -7.36869706e+00 3.99551760e-02
 -2.16156843e-03 8.42560336e-03 -1.25282085e-04 1.41984326e-04
 -7.05660613e-05 2.16126902e-05]]
```

```
***************
**************
Error medio Absoluto (MAE): 148054.32929226995
Root Mean Squared Error: 226183.7142848149
r2 score 0.6204144757159564
*************
Ridge
poly_features = PolynomialFeatures(degree=3, include_bias=False)
X poly = poly features.fit transform(X.values)
X_train_pr = poly_features.fit_transform(X_train)
X_test_pr = poly_features.fit_transform(X_test)
alpha = 10
ridge_model = Pipeline([
   ("poly_features", poly_features),
   ("scaler", StandardScaler()),
   ("ridge", Ridge(alpha=alpha, solver='cholesky', random_state=42))
])
ridge_model.fit(X_train_pr, y_train)
y_pred = ridge_model.predict(X_poly)
print("*****10)
print(f"intersección: {ridge model.named steps['ridge'].intercept }")
print(f"coefficientes: {ridge_model.named_steps['ridge'].coef_}")
print("*****10)
print("*****10)
ridge_reg_MAE, ridge_reg_RMSE, ridge_reg_r2 = calculo_errores(y, y_pred)
print("*****10)
**************
intersección: [540134.8392385]
coefficientes: [[ 43664.24048639 -19577.57212434 -28289.90533264 ... 21517.87988323
  11437.88203838 6731.38961475]]
**************
**************
Error medio Absoluto (MAE): 147416.11076243696
Root Mean Squared Error: 233653.59188662685
r2_score 0.5949283003652879
***************
Lasso
poly_features = PolynomialFeatures(degree=3, include_bias=False)
X_poly = poly_features.fit_transform(X.values)
X train pr = poly features.fit transform(X train)
X_test_pr = poly_features.fit_transform(X_test)
alpha = 10
lasso_model = Pipeline([
```

```
("poly_features", poly_features),
    ("scaler", StandardScaler()),
    ("lasso", Lasso(alpha=alpha, tol=1e-2, random state=42))
1)
lasso_model.fit(X_train_pr, y_train)
y_pred = lasso_model.predict(X_poly)
print("*****10)
print(f"intersección: {lasso_model.named_steps['lasso'].intercept_}")
print(f"coefficientes: {lasso_model.named_steps['lasso'].coef_}")
print("*****10)
lasso_reg_MAE, lasso_reg_RMSE, lasso_reg_r2 = calculo_errores(y, y_pred)
print("*****10)
C:\Users\bring\anaconda3\envs\tec\lib\site-packages\sklearn\linear_model\_coordinate_descent.py:648: Co.
 model = cd_fast.enet_coordinate_descent(
**************
intersección: [540134.83923849]
coefficientes: [ 18965.60705708 -11580.43136729 40030.12013694 ...
                                                                    -0
 -6721.4098935
                -8958.53137009]
**************
Error medio Absoluto (MAE): 147837.0988253276
Root Mean Squared Error: 241074.03642916318
r2 score 0.5687909589890132
**************
Visualización de los Errores en los cuatro métodos
error_comparison = {
   'Method' : ['Linear', 'Polinomial', 'Ridge', 'Lasso'],
    'MAE' : [lin_reg_MAE, poly_reg_MAE, ridge_reg_MAE, lasso_reg_MAE],
    'RMSE': [lin_reg_RMSE, poly_reg_RMSE, ridge_reg_RMSE, lasso_reg_RMSE],
    'R-squared' : [lin_reg_r2, poly_reg_r2, ridge_reg_r2, lasso_reg_r2],
}
error_comparison = {
   'Error' : ['MAE', 'RMSE', 'R-squared'],
    'Linear' : [lin_reg_MAE, lin_reg_RMSE, lin_reg_r2],
    'Polinomial' : [poly_reg_MAE, poly_reg_RMSE, poly_reg_r2],
    'Ridge' : [ridge_reg_MAE, ridge_reg_RMSE, ridge_reg_r2],
    'Lasso' : [lasso_reg_MAE, lasso_reg_RMSE, lasso_reg_r2]
}
error_comparison_df = pd.DataFrame(error_comparison)
error_comparison_df
                              Polinomial
      Error
                    Linear
                                                 Ridge
        MAE 164778.391645 148054.329292 147416.110762 147837.098825
0
       RMSE 248835.910200 226183.714285 233653.591887 241074.036429
1
2 R-squared
                  0.540577
                                0.620414
                                              0.594928
                                                             0.568791
error_comparison_df1 = error_comparison_df.drop([2], axis=0, inplace=False)
error_comparison_df1.reset_index()
```


sns.catplot(data=error\_comparison\_melt\_df1, x="Error value", y="Regression", hue='Error', kind="bar")
plt.show()




error\_comparison\_df2 = error\_comparison\_df.drop([0,1], axis=0, inplace=False)
error\_comparison\_df2.reset\_index()

```
index Error Linear Polinomial Ridge Lasso
0  2 R-squared 0.540577  0.620414 0.594928 0.568791
# Aplicamos un 'melt' que es un 'unpivot' de los datos para que podamos graficarlos
error_comparison_melt_df2 = pd.melt(
```

error\_comparison\_df2,
id\_vars="Error",
var\_name="Regression",
value\_name="Error value")





#### Explicación de Resultados

Primero sugerimos descartar el método de Lasso por el 'Warning' que nos sale de que no se logra la convergencia del modelo, intentamos aumentar el grado de ajuste en el modelo pero tenemos un error de desbordamiento de memoria. Por lo tanto, decidimos irnos por el modelo de Regresión Polinomial ya que es el que cuenta con el menor error con respecto a los otros modelos. Sin embargo, para poder determinar de forma más contundente el modelo, recomendamos que se haga un evaluación de puntaje de validación cruzada (cross validation).

Los porcentajes de entrenamiento fueron de 70% y 30% pero sobre el 50% de los datos totales para lograr conseguir la convergencia de los modelos, sin embargo, como habíamos comentado en la primera parte recomendamos hacer un análisis de 'underfitting' y 'overfitting' para analizar si los resultados no están subajustados o sobreajustados y de esta manera hacer una redefinición de los porcentajes en caso de ser necesario.

Los valores de error hay que revisarlos ya que se tienen muy altos para MAE y RMSE, podría deberse por la multidimensionalidad del modelo, aunque también consideramos revisar la precencia de outliers. Por otro lado, el valor de  $R^2 > 0$ , que nos indica que no hubo algún problema con el ajuste, en ridge y polinomial  $R^2 \approx 0.6$ , el modelo ideal, que ajustará perfectamente tendría una  $R^2 = 1$  lo cual nos habla de que nuestro error podría ser aceptable.

# Conclusiones

Con respecto al Ejercicio 1 no se presentaron complicaciones importantes para poder lograr la convergencia de los modelos y su ajuste para obtener la menor cantidad de error. Sin embargo en los modelos de regresión múltiple tuvimos problema para lograr la convergencia de los modelos, esto se puede deber al tamaño del 'dataset' y la gran multidimensional del modelo debido a la cantidad de atributos que se tenían.

Para poder hacerle frente a este desafío propusimos disminuir la cantidad de atributos, seleccionar sólo aquellos que consideramos los más importantes y de igual manera disminuir la cantidad de datos de entrenamiento y validación para evitar el desbordamiento de la memoria. Sin embargo, pese a que conseguimos que convergieran en la mayoría de los modelos y calcular el error, consideramos necesario hacer un análisis más exhaustivo como un PCA para explorar otras técnicas de reducción de complejidad y así explorar si se alcanza un mejor ajusto de los modelos y su modificación de parámetros para reducir el error.